Les pénuries de médicaments en France : prévisibles, contagieuses, importées ?

Ozan Taskin, Rahim Belkacemi
DALAS, Sorbonne Université – Livrable 1 : question de recherche et dataset
github.com/OzanTaskin/DALAS_DATASET

1 Question de recherche

Depuis 2021, les pénuries de médicaments se multiplient en Europe. Les agences sanitaires publient chaque jour la liste des pénuries en cours, mais personne ne cherche à les *anticiper*. Notre question principale :

Peut-on prévoir qu'une substance active va manquer en France, et pourquoi ?

Deux questions en découlent. **Les pénuries se propagent-elles** d'un médicament à ses substituts, vers lesquels les prescriptions se reportent ? **Sont-elles importées**, c'est-à-dire annoncées par une pénurie de la même substance en Italie ou en Allemagne ? Nous travaillons sur la France parce que c'est le seul pays pour lequel nous disposons de la liste complète des médicaments commercialisés, y compris ceux qui ne manquent jamais : sans eux, impossible d'apprendre ce qui distingue une substance fragile d'une substance robuste.

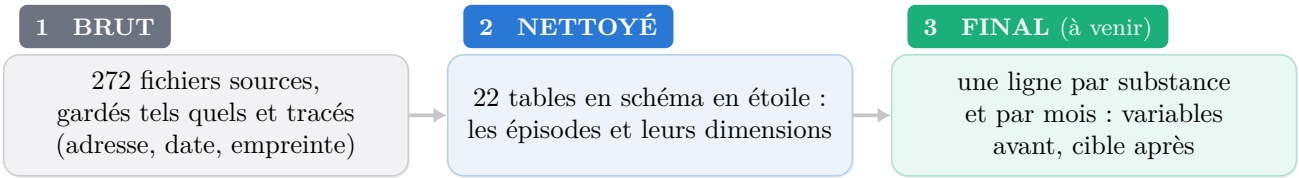
2 Collecte et construction du dataset

Les sources. Toutes les données sont officielles et publiques :

- **ANSM** (agence française) : la page publique des pénuries, et les signalements de rupture que les laboratoires doivent lui déclarer, publiés chaque année depuis 2019 ;
- **BDPM** (base publique du médicament) : tous les médicaments vendus en France ;
- **Open Medic** (Assurance Maladie) : les boîtes remboursées par an et la classification ATC des substances ;
- **AIFA** et **BfArM** : les listes de pénuries italienne et allemande.

Ces listes ne montrent que le *présent* : une pénurie terminée disparaît. Pour reconstruire le passé, nous avons récupéré les **archives mensuelles de la Wayback Machine**, une photo de chaque liste par mois depuis 2021 (2024 pour l'Allemagne, 2015 pour la base des médicaments).

Une construction en trois niveaux, comme un entrepôt de données (cours *Building a Dataset from a Warehouse*, TP MegaStore) :



Trois éléments du cours y sont appliqués :

- le **sens d'une ligne** (grain) de chaque table est écrit et vérifié ;
- la base des médicaments est **historisée** (une version par période, jointure *as-of*), pour décrire le marché tel qu'il était à chaque date ;
- chaque construction est **contrôlée et tracée** : aucune ligne perdue ni dupliquée, et un manifeste dit si un écart vient du code ou des données.

3 Le dataset

Le tableau 1 donne le nombre d'observations des principales tables, et le tableau 2 le sens des variables d'un épisode de pénurie. Les **signalements** français serviront de cible à la prédiction.

Table	Une ligne =	Lignes	Période
Épisodes, France	une pénurie publiée par l'ANSM	1 599	2021–2026
Épisodes, Italie	une pénurie publiée par l'AIFA	10 035	2021–2026
Épisodes, Allemagne	une pénurie publiée par le BfArM	2 000	2024–2026
Signalements, France	une déclaration d'un laboratoire à l'ANSM	22 501	2019–2025
Médicaments, France	un médicament commercialisé	13 650	2026

Tableau 1 – Les principales tables et leur nombre d'observations.

Variable	Signification
`atc5`	la substance active (code ATC niveau 5) : la clé qui relie les pays entre eux
`atc4`	la classe thérapeutique : les substances d'une même classe sont des substituts
`debut`, `fin`	le début et la fin de la pénurie
`publication`	la date à laquelle la pénurie apparaît sur la liste, c'est-à-dire devient connue
`gravite`	en France : risque de rupture, tension ou rupture
`raison`	en Italie et en Allemagne : la cause déclarée (production, forte demande…)

Tableau 2 – Les variables principales d'un épisode de pénurie.

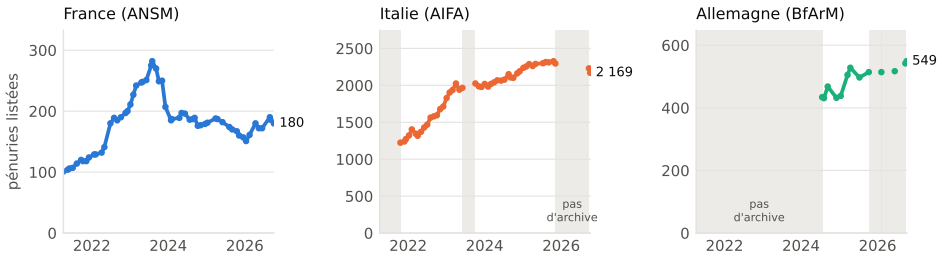


Figure 1 – Nombre de pénuries en cours sur chaque archive mensuelle. Zones grises : mois sans archive.

Trois constats ressortent déjà (figure 1) :

- en France, les pénuries culminent pendant l'hiver 2022-2023, au moment de la crise des antibiotiques ; une pénurie dure en général environ **4 mois**, et près d'une sur cinq plus d'un an ;
- **un tiers des substances** vendues en France a connu au moins une pénurie depuis 2021 ;
- près de **trois substances françaises en pénurie sur quatre** l'ont aussi été en Italie ou en Allemagne, ce qui rend la question des pénuries importées pertinente.

4 Prétraitement et choix

Relier les sources entre elles. Ni l'ANSM ni la BDPM n'indiquent la substance sous forme de code. Nous la retrouvons en croisant les sources (boîte, nom, substance) : 9 lignes sur 10 sont reliées.

Passer des photos aux épisodes. Une archive mensuelle n'est qu'une photo. Nous regroupons les photos successives d'un même médicament en un épisode, avec une date de début et une date de fin.

Ne jamais utiliser le futur. Pour prédire, on ne doit utiliser que ce qui était connu au moment de la prédiction. Nous gardons donc la date de `publication` d'une pénurie à côté de sa date de début : le début déclaré est parfois connu après coup, ou annoncé à l'avance.

Écarter ce qui fausserait les données. Les arrêts définitifs de commercialisation ne sont pas des pénuries, et certaines archives ont été tronquées par la Wayback Machine : les deux sont exclus.

Limites. Les signalements ne concernent que les médicaments jugés essentiels, et les pays ne définissent pas une pénurie de la même façon : ces différences seront prises en compte dans l'analyse.