**Les pénuries de médicaments en France : prévisibles, contagieuses, importées ?**

Ozan Taskin, Rahim Belkacemi – DALAS, Sorbonne Université – Livrable 1

github.com/OzanTaskin/DALAS_DATASET

# 1 Question de recherche

Les agences publient la liste des pénuries de médicaments en cours, jamais de prévision : patients et soignants les découvrent une fois la rupture installée. Notre question principale :

> **Quelles substances actives risquent de manquer en France dans les trois prochains mois, et quels facteurs expliquent leur vulnérabilité** : criticité du médicament, niveau de demande, historique de pénuries, propagation à partir des substituts, pénuries déjà observées chez nos voisins européens ?

Nous la mesurons ainsi : une substance fera-t-elle l'objet d'**au moins un signalement de rupture à l'ANSM dans les trois mois**, d'après les seules informations déjà publiques ? Prévoir quelles substances sont menacées permettrait d'anticiper les tensions d'approvisionnement ; comprendre pourquoi, d'agir sur les causes. Deux mécanismes sont testés :

> **Q1, effet cascade.** Une rupture se propage-t-elle aux substances de la même classe, qui servent de substituts ?

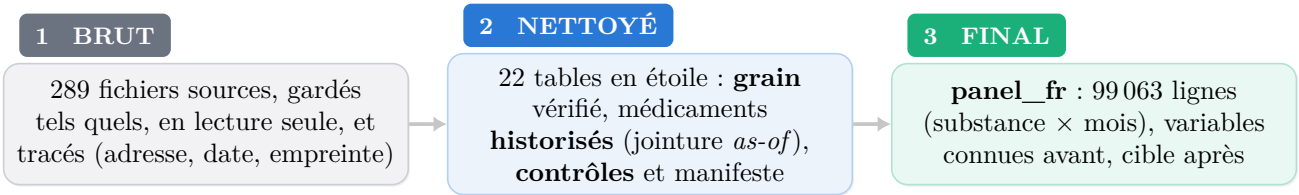
> **Q2, pénuries importées.** Une pénurie déjà présente en Italie, en Allemagne ou dans un autre pays de l'Union européenne annonce-t-elle la pénurie française ?

Périmètre : la France (seul pays avec tous les médicaments commercialisés) et 1 223 substances à médicament d'intérêt thérapeutique majeur (MITM), seules soumises à déclaration. Pour Q2, l'Italie et l'Allemagne sont déjà intégrées ; d'autres pays de l'Union pourront s'y ajouter.

# 2 Collecte et construction du dataset

Toutes les données viennent de sources officielles et publiques : ANSM, BDPM, Open Medic, AIFA (Italie) et BfArM (Allemagne). Ces listes ne montrent que le *présent* : pour reconstruire le passé, nous avons récupéré les **archives de la Wayback Machine**, des photos environ mensuelles quand elles existent (tableau 1).

**Une construction en trois niveaux**, comme un entrepôt de données : nous y appliquons les éléments du cours *Building a Dataset from a Warehouse* et du TP MegaStore.




# 3 Le dataset

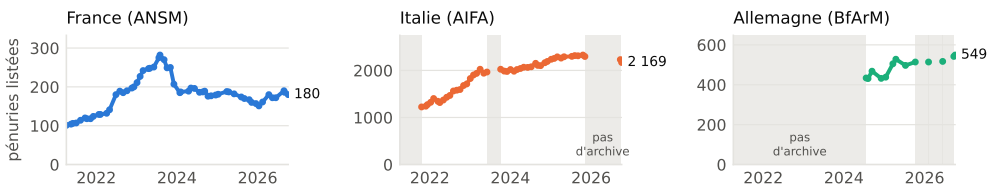
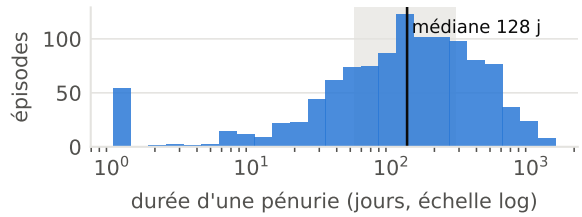



**Figure 1** – Pénuries en cours par archive (zones grises : plus de 100 jours sans archive).




**Durées (France, 1 130 pénuries terminées).** Distribution asymétrique (moyenne 209 j, médiane **128 j**, quartiles **53 et 284 j**, **18 %** au-delà d'un an) : nous retenons médiane et quartiles, pas la moyenne. Les valeurs extrêmes sont conservées, car exceptionnelles mais exactes.

**35 %** des substances commercialisées ont connu une pénurie en France depuis 2021. Les signalements suivent la consommation (Spearman **0,61**) et le nombre de présentations (**0,79**), lié lui aussi à la consommation (0,68) : lien confondu (cohorte, 858 substances).

| Épisodes de pénurie | France (ANSM) | Italie (AIFA) | Allemagne (BfArM) |
|---|---|---|---|
| Nombre (dont en cours) | 1 599 (180) | 10 035 (2 169) | 2 000 (549) |
| Substances · ATC connu | 543 · 94,1 % | 1 073 · 93,5 % | 509 · 96,8 % |
| Photos · période | 59 · 04/2021–10/2026 | 48 · 10/2021–10/2026 | 13 · 07/2024–10/2026 |

**Tableau 1** – Description par pays (hors 3 135 arrêts de commercialisation italiens).

| Table | Une ligne = | Lignes × col. | Variables principales |
|---|---|---|---|
| Épisodes de pénurie | une pénurie d'un médicament dans un pays | 16 769 × 17 | `atc5` substance (clé commune) ; `atc4` classe de substituts ; `debut`, `fin` ; `publication` date où elle devient connue ; `gravite`, `raison` |
| Signalements | un signalement d'un laboratoire (1 504 en 2019, 4 925 en 2023) | 22 501 × 9 | `date_signalement`, `laboratoire`, `atc5` |
| Médicaments | un médicament de la BDPM (13 650 commercialisés) | 15 883 × 16 | `forme`, `voies`, `titulaires`, `atc5` |
| Consommation | une substance et une année (Open Medic) | 8 045 × 5 | `boites`, `montant_rembourse` |
| Panel (niveau 3) | une substance MITM par mois | 99 063 × 15 | `cible` ; Q1 : `fr_autres_classe_3m` ; Q2 : `it_affichee_3m`, `de_affichee_3m` |

**Tableau 2** – Tables principales (22 au niveau 2 + le panel) : une ligne, dimensions, variables.

## 4 Prétraitement et choix

**Relier les sources.** L'ANSM et la BDPM ne donnent pas la substance sous forme de code : nous la retrouvons en croisant boîte, nom et substance (**9 lignes sur 10**).

**Photos en épisodes.** Les photos successives d'un médicament forment un épisode (Italie : présence continue, l'AIFA révisant les dates). Les « N/A » allemands (un quart des lignes) sont traités comme vides ; arrêts définitifs et archives tronquées écartés.

**Qualité.** Aucun doublon ni boîtes nulles. Fin vide = pénurie en cours (**11 %** en France, **27 %** en Allemagne) ; ATC absent (**3 à 6 %**) = hors jointures ; **46** durées nulles gardées ; aucune imputation.

**Pas de futur.** Chaque variable n'utilise que ce qui était connu à la fin du mois (`publication`, non début déclaré) ; un contrôle recalcule les variables avec les seules données publiées à une date donnée.

## 5 Faisabilité et limites

La cible vaut 1 pour **24 %** des lignes (**24 101** positives sur 99 063) : ni trop rare, ni dominante. Part de positifs avec et sans signal sur les 3 mois précédents (écarts bruts) : **Q2 Italie 53 % contre 16 %** ; Q1 **31 % contre 27 %** ; Allemagne 48 % contre 25 % (13 mois d'archives à ce jour). Ces écarts ne tiennent pas compte de la consommation, du nombre de présentations ni de l'historique de chaque substance : l'étape suivante les contrôle.

**Limites.** Signalements sans date de fin ; cohorte fondée sur la liste MITM de 2026 (97,5 % des signalements) ; archives irrégulières ; définition de la pénurie variable selon les pays ; taux de positifs en hausse au fil des années.