Les pénuries de médicaments en France : prévisibles, contagieuses, importées ?

Ozan Taskin, Rahim Belkacemi
DALAS, Sorbonne Université – Livrable 1 : question de recherche et dataset
github.com/OzanTaskin/DALAS_DATASET

1 Question de recherche

Depuis 2021, les pénuries de médicaments se multiplient en Europe. Les agences sanitaires publient la liste des pénuries en cours, mais *aucune prévision* : patients et soignants les découvrent une fois la rupture installée. Notre question principale :

> **Quels médicaments risquent de manquer en France dans les prochains mois, et quels facteurs les rendent vulnérables ?**

Pour la mesurer, nous demandons si une substance active fera l'objet d'**au moins un signalement de rupture à l'ANSM dans les trois mois suivants**, avec les seules informations publiques déjà disponibles. L'enjeu est de comprendre ce qui rend une substance fragile. Nous testons deux mécanismes, en comparant substances exposées au signal et autres :

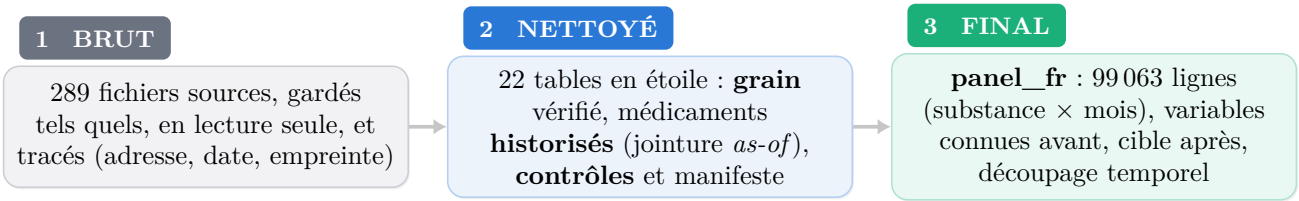
> **Q1, effet cascade.** Une rupture se propage-t-elle aux substances de la même classe thérapeutique, celles qui servent de substituts ?
>
> **Q2, pénuries importées.** Une pénurie déjà présente en Italie ou en Allemagne annonce-t-elle la pénurie française ?

Nous étudions la France (seul pays avec tous les médicaments commercialisés) et les 1 223 substances à médicament d'intérêt thérapeutique majeur (MITM), seules soumises à déclaration (3 % de cas positifs pour les autres, contre 24 %).

2 Collecte et construction du dataset

Toutes les données viennent de sources officielles et publiques : ANSM, BDPM, Open Medic, AIFA (Italie) et BfArM (Allemagne). Ces listes ne montrent que le *présent* : pour reconstruire le passé, nous avons récupéré les **archives de la Wayback Machine**, des photos environ mensuelles quand elles existent (tableau 1).

Une construction en trois niveaux, comme un entrepôt de données : nous y appliquons les éléments du cours *Building a Dataset from a Warehouse* et du TP MegaStore.



3 Le dataset

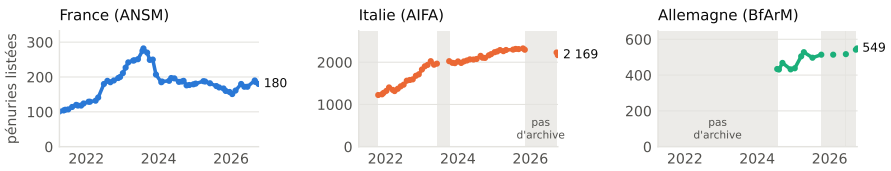
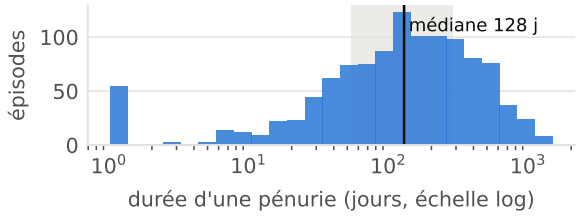


Figure 1 – Pénuries en cours par archive (zones grises : plus de 100 jours sans archive).



Durées (France, 1 130 pénuries terminées). Distribution asymétrique (moyenne 209 j, médiane **128 j**, quartiles 53 et 284 j, 18 % au-delà d'un an) : nous retenons médiane et quartiles, pas la moyenne. Les valeurs extrêmes sont conservées, car exceptionnelles mais exactes.

35 % des substances commercialisées ont connu une pénurie en France depuis 2021. Les signalements suivent la consommation (Spearman 0,49) et le nombre de présentations (0,66), lié lui aussi à la consommation (0,64) : lien confondu.

Épisodes de pénurie	France (ANSM)	Italie (AIFA)	Allemagne (BfArM)
Nombre (dont en cours)	1 599 (180)	10 035 (2 169)	2 000 (549)
Substances · ATC connu	543 · 94,1 %	1 073 · 93,5 %	509 · 96,8 %
Photos · période	59 · 04/2021–10/2026	48 · 10/2021–10/2026	13 · 07/2024–10/2026
Gravité · cause déclarée	60 % tensions, 40 % ruptures	47 % production, 13 % demande	37 % production, 63 % autre

Tableau 1 – Description par pays (hors 3 135 arrêts de commercialisation italiens).

Table	Une ligne =	Lignes × col.	Variables principales
Épisodes de pénurie	une pénurie d'un médicament dans un pays	16 769 × 17	`atc5` substance, clé commune aux pays ; `atc4` classe de substituts ; `debut`, `fin` ; `publication` date où elle devient connue ; `gravite` ; `raison` cause déclarée
Signalements	un signalement d'un laboratoire (1 504 en 2019, 4 925 en 2023)	22 501 × 9	`date_signalement`, `laboratoire`, `atc5`
Médicaments	un médicament de la BDPM (13 650 commercialisés)	15 883 × 16	`forme`, `voies`, `titulaires`, `atc5`
Consommation	une substance et une année (Open Medic)	8 045 × 5	`boites`, `montant_rembourse`
Panel (niveau 3)	une substance MITM par mois	99 063 × 15	`cible`, `jeu` ; Q1 : `fr_autres_classe_3m` ; Q2 : `it_affichee_3m`, `de_affichee_3m`

Tableau 2 – Les tables principales (22 au total) : sens d'une ligne, dimensions et variables principales.

4 Prétraitement et choix

Relier les sources. L'ANSM et la BDPM ne donnent pas la substance sous forme de code : nous la retrouvons en croisant boîte, nom et substance (9 lignes sur 10).

Photos en épisodes. Les photos successives d'un médicament forment un épisode (en Italie, une présence continue sur la liste, car l'AIFA révise les dates de début). Les « N/A » allemands (un quart des lignes) sont traités comme vides ; les arrêts définitifs et les archives tronquées sont écartés.

Qualité. Aucun doublon ni boîtes nulles. Fin vide = pénurie en cours (11 % en France, 27 % en Allemagne) ; ATC absent (3 à 6 %) = hors jointures ; 46 durées nulles gardées ; aucune imputation.

Pas de futur. Chaque variable n'utilise que ce qui était connu à la fin du mois (`publication` d'une pénurie, non son début déclaré). Un contrôle recalcule le panel avec les seules données publiées à une date donnée.

5 Faisabilité et limites

La cible vaut 1 pour 24 % des lignes ; entraînement jusqu'à 09/2023, validation en 2024, test en 2025 (11 007 lignes, 3 070 positives), avec 3 mois d'écart entre jeux. Part de positifs avec et sans signal sur les 3 mois précédents (écarts bruts) : **Q2 Italie** 53 % contre 16 % (46 mois, testable) ; Allemagne 48 % contre 25 % (13 mois, indicatif) ; Q1 31 % contre 27 % (écart faible).

Limites. Signalements sans date de fin ; cohorte fondée sur la liste MITM de 2026 ; archives irrégulières ; définition de la pénurie variable selon les pays ; taux de positifs en hausse (22 % à 28 %).