Les pénuries de médicaments en France : prévisibles, contagieuses, importées ?

Ozan Taskin, Rahim Belkacemi

DALAS, Sorbonne Université – Livrable 1 : question de recherche et dataset

github.com/OzanTaskin/DALAS_DATASET

1 Question de recherche

Depuis 2021, les pénuries de médicaments se multiplient en Europe. Les agences sanitaires publient la liste des pénuries en cours, *sans prévision*. Notre question principale :

Peut-on prévoir qu'une substance active va manquer en France, et pourquoi ?

Deux questions en découlent. **Les pénuries se propagent-elles** d'un médicament à ses substituts, vers lesquels les prescriptions se reportent ? **Sont-elles importées**, c'est-à-dire annoncées par une pénurie de la même substance en Italie ou en Allemagne ? Nous travaillons sur la France parce que c'est le seul pays pour lequel nous disposons de la liste complète des médicaments commercialisés, y compris ceux qui ne manquent jamais : sans eux, impossible d'apprendre ce qui distingue une substance fragile d'une substance robuste.

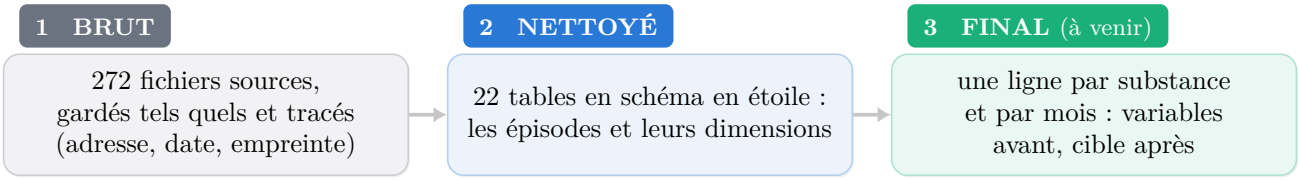
2 Collecte et construction du dataset

Les sources. Toutes les données sont officielles et publiques :

- **ANSM** (agence française) : la page publique des pénuries, et les signalements de rupture que les laboratoires doivent lui déclarer, disponibles pour 2019–2025 ;
- **BDPM** (base publique du médicament) : tous les médicaments vendus en France ;
- **Open Medic** (Assurance Maladie) : les boîtes remboursées par an et la classification ATC ;
- **AIFA** et **BfArM** : les listes de pénuries italienne et allemande.

Ces listes ne montrent que le *présent* : une pénurie terminée disparaît. Pour reconstruire le passé, nous avons récupéré les **archives de la Wayback Machine** : des photos d'archives, environ mensuelles quand elles existent, depuis 2021 (2024 pour l'Allemagne, 2015 pour la base des médicaments).

Une construction en trois niveaux, comme un entrepôt de données (cours *Building a Dataset from a Warehouse*, TP MegaStore) :



Trois éléments du cours y sont appliqués :

- le **sens d'une ligne** (grain) des tables principales est écrit et vérifié ;
- la base des médicaments est **historisée** (une version par période, jointure *as-of*), pour décrire le marché tel qu'il était à chaque date ;
- chaque construction est **contrôlée et tracée** : pertes mesurées et plafonnées, et un manifeste dit si un écart vient du code ou des données.

3 Le dataset

Le tableau 1 donne le nombre d'observations des principales tables, et le tableau 2 le sens de leurs variables principales. Les **signalements** français serviront de cible à la prédiction.

Table	Une ligne =	Lignes	Période
Épisodes, France	une pénurie publiée par l'ANSM	1 599	2021–2026
Épisodes, Italie	une pénurie publiée par l'AIFA	10 035	2021–2026
Épisodes, Allemagne	une pénurie publiée par le BfArM	2 000	2024–2026
Signalements, France	une déclaration d'un laboratoire à l'ANSM	22 501	2019–2025
Médicaments, France	un médicament commercialisé	13 650	2026

Tableau 1 – Les principales tables et leur nombre d'observations.

Variable	Signification
`atc5`	la substance active (code ATC niveau 5), clé commune aux trois pays
`atc4`	la classe thérapeutique : ses substances sont des substituts
`debut`, `fin`	le début et la fin de la pénurie
`publication`	la date où la pénurie apparaît sur la liste (devient connue)
`gravite`	en France : risque de rupture, tension ou rupture
`raison`	en Italie et en Allemagne : la cause déclarée (production, demande…)
`date_signalement`	signalements : date de la déclaration et laboratoire déclarant
`forme`, `voies`	médicaments : forme, voie d'administration (et laboratoires titulaires)
`boites`	consommation : les boîtes remboursées par substance et par an

Tableau 2 – Les variables principales : épisodes, signalements, médicaments et consommation.

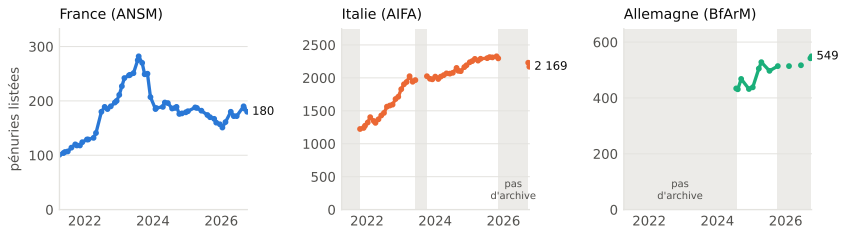


Figure 1 – Pénuries en cours par archive. Zones grises : périodes de plus de 100 jours sans archive.

- en France, les pénuries culminent pendant l'hiver 2022-2023, au moment de la crise des antibiotiques (figure 1) ; une pénurie dure environ **4 mois**, et près d'une sur cinq plus d'un an ;
- **un tiers des substances** vendues en France a connu au moins une pénurie depuis 2021 ;
- près de **3 substances françaises en pénurie sur 4** l'ont aussi été en Italie ou en Allemagne.

4 Prétraitement et choix

Relier les sources entre elles. Ni l'ANSM ni la BDPM n'indiquent la substance sous forme de code. Nous la retrouvons en croisant les sources (boîte, nom, substance) : 9 lignes sur 10 sont reliées.

Passer des photos aux épisodes. Une archive n'est qu'une photo : nous regroupons les photos successives d'un même médicament en un épisode (début, fin). Deux corrections évitent de fausses pénuries : en Italie, l'AIFA révise souvent la date de début d'une pénurie déjà listée, un épisode est donc une présence continue sur la liste ; en Allemagne, un quart des lignes ont une déclaration initiale « N/A » qui formait à tort un seul épisode : elle est traitée comme vide.

Ne jamais utiliser le futur. Pour prédire, on ne doit utiliser que ce qui était connu au moment de la prédiction. Nous gardons donc la date de `publication` d'une pénurie à côté de sa date de début : le début déclaré est parfois connu après coup, ou annoncé à l'avance.

Écarter ce qui fausserait les données. Les arrêts définitifs de commercialisation ne sont pas des pénuries, et certaines archives ont été tronquées par la Wayback Machine : les deux sont exclus.

Limites. Les signalements ne concernent que les médicaments d'intérêt thérapeutique majeur, seuls soumis à déclaration, sans date de fin ni statut. Les archives sont irrégulières : une pénurie courte peut passer entre deux photos, et le marché a des trous d'historique entre 2020 et 2024. Les pays définissent la pénurie différemment, et une part de la hausse des signalements peut venir de déclarations renforcées.